

Veri Setinin Keşifsel Analizi (EDA)

165.349 araç kutusu, 6.471 eğitim görüntüsü ve 2.118 test görüntüsü üzerinde yapılan incelemenin bulguları. Asıl amaç: submission'ın %60'ı private olduğu için modelin train dağılımına değil genel araç görünümüne overfit etmesini sağlamak.

Sınıflar: **car** · **van** · **truck** · **bus** Metrik: **mAP@0.5** (4 sınıf ortalaması) Min kutu alanı: **200 px²**

6.471 train görüntüsü	2.118 test görüntüsü	165.349 etiketli kutu
26,8 ort. kutu / görüntü	290 araçsız train görüntüsü	8 farklı çözünürlük

En kritik bulgu: train / test çözünürlük kayması

Görüntü çözünürlüğüne göre gruplayınca train ve test setlerinin **aynı dağılımdan gelmediği** ortaya çıkıyor. Bu, rastgele değil sahne/uçuş bazlı bir split olduğunu gösteriyor — overfit riskini doğrudan etkileyen en önemli sinyal bu.




2000×1500 çözünürlüğü train'in %12,2'si, test'te ise %0

756 train görüntüsü (tüm etiketli görüntülerin ~%12'si) test setinde hiç temsil edilmeyen bir çözünürlükte. Buna karşılık test'in en baskın grubu (1400×788, %44) train'de sadece %20 pay alıyor. Bu görüntüler muhtemelen farklı uçuşlardan/kameralardan geliyor — **class mix de çözünürlüğe göre değişiyor** (aşağıya bakın), yani bu sadece piksel boyutu değil, sahne kompozisyonu farkı.


ÇÖZÜNÜRLÜK	TRAIN %	TEST %	FARK
1400×1050	38,36	12,94	-25,4
1400×788	20,35	44,05	+23,7
2000×1500	12,23	0,00	-12,2
1360×765	11,49	26,25	+14,8
1916×1078	8,40	7,13	-1,3
1920×1080	5,47	2,36	-3,1

ÇÖZÜNÜRLÜK	TRAIN %	TEST %	FARK
960×540	3,19	7,27	+4,1
1398×1048	0,49	0,00	-0,5

Fark sütunu test%-train% farkının mutlak büyüklüğüne göre vurgulanmıştır. 2000×1500 ve 1398×1048 test setinde tamamen yok.



Train seti çözünürlük dağılımı — 1400×1050 baskın.




Test seti çözünürlük dağılımı — 1400×788 baskın, 2000×1500 yok.


Sınıf dağılımı ve dengesizlik

Sınıflar arası ciddi bir dengesizlik var: car kutuların **%75,5**'ini oluştururken bus yalnızca **%3,4**. mAP dört sınıfın AP'sini **eşit ağırlıkla** ortalıyor, yani nadir görülen bus/truck sınıflarındaki zayıf performans, car'daki güçlü performansla aynı ağırlıkta puanı etkiliyor.

SINIF	KUTU SAYISI	PAY	MEDYAN ALAN (PX ²)	MEDYAN W×H
car	124.843	75,51%	1.472	44×34
van	22.787	13,78%	1.599	43×37
truck	12.109	7,32%	2.409	53×46
bus	5.610	3,39%	2.648	52×50



Mutlak kutu sayıları — car diğer üç sınıfın toplamından fazla.



w×h dağılımı: sınıflar arasında güçlü boyut örtüşmesi var, boyut tek başına ayırt edici değil.




Bus dağılımı da çözünürlüğe göre değişiyor

1400×788 görüntülerinde bus payı %10,6 iken diğer çözünürlüklerde %1–4 arasında.


Bu, bahsedilen çözünürlük kaymasının rastgele olmadığını, farklı sahnelerin (ör. otobüs güzergahı içeren bir bölge) farklı çözünürlük gruplarına denk geldiğini gösteriyor.

Kutu boyutu dağılımı

Alan dağılımı sağa çarpık (medyan 1.568 px², ortalama 4.241 px²) — çoğu araç küçük, birkaç büyük outlier (maks. 328.640 px², muhtemelen çok yakın çekim veya etiket hatası) ortalamayı yukarı çekiyor. Tüm kutular zaten ≥ 200 px² — yarışma kuralına uygun şekilde train seti önceden filtrelenmiş, ekstra filtre gerekmiyor.



log10(alan) dağılımı, sınıf bazlı. Kesikli çizgi 200 px² eşikliğini gösteriyor — dağılımın sol ucu tam eşikte kesiliyor.



Görüntü başına araç sayısı: medyan 21, maks. 218 (yoğun kavşak/otopark sahneleri).

Veri kalitesi

Genel olarak temiz bir veri seti — ciddi bir etiket bozukluğu bulunamadı:



KONTROL	SONUÇ
Görüntü sınırları dışına taşan kutu	0
Bozuk kutu (w veya $h \leq 0$)	0
Birebir aynı (duplicate) kutu satırı	1
200 px ² 'den küçük kutu	0
Etiket dosyasında olup görseli eksik	0
Araçsız (boş) train görüntüsü	290 / 6.471 (%4,5)

Ayrıca image_id'ler aynı çözünürlükte 5–9'luk ardışık bloklar halinde kümeleniyor (132 blok tespit edildi) — bu da görüntülerin videodan çıkarılmış ardışık kareler olabileceğine işaret ediyor. Yakın-kopya kareler train/val arasında sızıntıya (leakage) yol açabilir.

Örnek etiketli görüntüler

Train setinden rastgele seçilmiş 6 görüntü, sınıf renklerine göre kutulanmış.

● car ● van ● truck ● bus



Overfit'ten kaçınmak için öneriler

%60'lık private bölüme göre sıralama yapılacağı için, aşağıdaki öncelik sırasına göre hareket etmenizi öneririz.

DOĞRULAMA STRATEJİSİ	Rastgele random split ile local validation kurmayın. Çözünürlük dağılımı train/test arasında farklı olduğu için rastgele split, gerçekte olmayan bir iyimserlik yaratır. Bunun yerine çözünürlük/sahne grubuna göre GroupKFold kurun; en az bir fold'da train'e özgü 2000×1500 grubunu tamamen dışarıda bırakarak modelin görmediği dağılıma ne kadar genelleyebildiğini ölçün.
KARE SIZINTISI	Ardışık image_id bloklarını (aynı fold) birlikte tutun. 132 adet 5-9 görüntülük ardışık aynı-çözünürlük bloğu bulundu; bunlar muhtemelen video karelerinden geliyor. Neredeyse aynı kareleri train'e ve val'e ayrı ayrı koymak validation skorunu yapay olarak şişirir.
SINIF DENGESİZLİĞİ	Bus ve truck için oversampling / class-weighted loss / copy-paste augmentasyon uygulayın. mAP dört sınıfı eşit ağırlıklandırıyor; bus sadece %3,4 örnekle car'la (%75,5) aynı ağırlığa sahip. Dengesiz eğitim, toplam skoru en çok bus/truck AP'sinin düşük kalması üzerinden aşağı çeker.
ÖLÇEK AUGMENTASYONU	Agresif multi-scale / mosaic / random-resize augmentasyon kullanın. Kutu genişlikleri 8-983 px, yükseklikler 6-790 px arasında değişiyor; ayrıca train/test farklı çözünürlük karışımına sahip. Modelin belirli bir piksel ölçeğine kilitlenmemesi için ölçek çeşitliliği kritik.
LEADERBOARD DISİPLİNİ	Public LB'deki küçük iyileşmelere güvenmeyin, grouped-CV skorunu esas alın. Public bölüm test setinin sadece %40'ı ve yarışma 19 saat sürüyor — az veri + kısa süre, LB'yi gürültülü ve overfit'e açık hale getirir. Model seçimini local CV skoruna göre yapın, LB'yi sadece sağlık kontrolü olarak kullanın.
KÜÇÜK KUTU POLİTİKASI	200 px²'den küçük tahminleri filtrelemeye gerek yok, ama agresif de üretmeyin. Kural gereği bu tahminler skoru etkilemiyor (ne ceza ne katkı), o yüzden confidence eşliğini bunlar için özel olarak ayarlamaya gerek yok; asıl enerjiyi ≥200 px² aralığındaki doğru sınıflandırma ve konumlandırmaya verin.

Analiz kapsamı: train/annotations.csv (165.349 satır), train/test görüntü meta verileri (tüm dosyalar okunarak boyutları çıkarıldı). Script'ler ve ara çıktılar eda_outputs/ klasöründe.